



暨南大学
JINAN UNIVERSITY

研究生课程论文

论文题目: 语言模型微调实践

课程名称: 自然语言处理

学 院: 智能科学与工程学院/人工智能产业学院

学 系:

专 业: 计算机科学与技术(人工智能方向)专业

高级研修项目

学生姓名: 陈燕松

学 号: 202560204520004

指导教师: 汤知日

2026 年 05 月 31 日

语言模型微调实践

【摘要】 本项目记录了对向量模型和大语言模型的使用的微调的经历,及针对问答任务微调的实践效果分享。涉及利用 bge-m3 关于检索任务的实践,及 LORA 微调的实践,及配合 LLM 组建 RAG 增强技术的实践,以及针对 Qwen/Qwen3.5-0.8B-Base 尝试 CPT 及 LoRA 微调任务。项目代码已上传到 <https://github.com/EthanGD/NLPHomeWork20260530/tree/main>

【关键词】 NLP; LLM; CPT; LoRA; SFT; Sentence Similarity

1 引言

本次实践的目的,是假想就普通中小企业为用户,在有限的算力资源下,实践各种方式接入模型不具有的知识,实验各种方式下问答任务的效果。目前面临的背景限制,其一是算力有限,其二是数据集规模较小,其三是开源的模型不具备特定深层领域的知识。本研究目的,是为探究如何在此限制前提下,扩展本地模型对特定深层领域的知识,提升领域问答效果。由于算力和数据集都有限,难以支持 LLM 的完整训练,在研究的过程中只收集了微调的方法。最终选择优先实验对算力和数据规模要求低的 LoRA 和 RAG 增强方法进行研究。考虑到希望 LLM 本身可以理解领域知识,后来也加入了 CPT 方法进行研究。已尝试过的实验已上传到 GitHub 上,各实验项目代码介绍如下:

项目代码 v1 包含以下模块:

- (1) 利用 bge-m3 向量化问答对存储到数据库,并支持增删,及根据相似度检索,相当于知识库管理模块。
- (2) LoRA 微调 bge-m3。
- (3) 构建 RAG 范式 Agent,对比微调 bge-m3 的作用。

项目代码 v2 测试了 Qwen3.5-0.8B 原模型的生成效果。以及利用 208 组关于 OpenClaw 的问答对，用 LoRA 微调 Qwen3.5-0.8B，并测试微调好的模型的生成效果。

项目代码 v3，利用 6 本中医针灸书籍的文本内容，使用 CPT（继续预训练方法）微调 Qwen3.5-0.8B，并测试原模型与微调好的模型的生成效果。

项目代码 v4，利用 6 本中医针灸书籍的文本内容，使用 Qwen3.5-122B 生成问答对。使用 LoRA 微调 Qwen3.5-0.8B，并试验效果。

本文的主要贡献包括：（1）系统比较了嵌入模型微调、LoRA 生成微调、继续预训练、LoRA+SFT 四种领域适配方法，在同一计算资源约束下提供了可复现的对比基准；（2）深入分析了继续预训练中灾难性遗忘的表征和成因，并验证了 SFT 作为恢复手段的有效性；（3）探索了大模型生成数据辅助小模型微调的可行性，为中小企业数据不足问题提供了低成本的解决方案。

2 实验环境

L20 单卡，Python 3.11

3 数据准备

3.1 数据来源 1

利用爬虫爬取来自网络 OpenClaw 问答对（<https://docs.openclaw.ai/zh-CN/help/faq>、<https://fetchopenclaws.com/answers>、<https://www.meta-intelligence.tech/insight-openclaw-faq>）。

3.2 数据来源 2

下载来自 HuggingFace 的中医针灸文本集（<https://huggingface.co/datasets/wobure/zhongyi-books>）。

4 v1 : bge-m3

4.1 实验目的

利用处理好的问答对，针对向量模型 BAAI/bge-m3，进行 LoRA 微调，观察效果。同时构建 RAG 范式的 Agent，观察 RAG 生成、纯 LLM 生成，纯词向量检索之间的效果差异。


4.2 数据与预处理

数据来源为 3.1 所提来自网络的 208 条关于 OpenClaw 的问答对(Query-Positive 配对)。按照 80/20 比例划分为训练集(166 条)和测试集(42 条)。每条样本格式为 anchor (查询) 和 positive (正确答案)，负样本在训练过程中动态采样。

4.3 向量模型 LoRA 训练配置


配置项	值
基础模型	BAAI/bge-m3 (SentenceTransformer 框架)
损失函数	MultipleNegativesRankingLoss
训练轮数	10 epochs
Batch Size	4×2 (梯度累积) = 8
学习率	$2e-5$
精度	bf16
优化器	AdamW
评估策略	每 epoch 评估

4.4 RAG 结构



本实验构建了 RAG(检索增强生成)系统,将向量检索与 LLM 生成相结合,通过 bge-m3 进行语义检索,再将检索结果作为上下文输入 LLM 进行答案生成。

4.5 实验结果



训练 Loss 从初始 0.182 降至最终 0.020，降幅达 89%，表明模型良好收敛。评估结果如下：

指标	训练集	测试集	备注
准确率	100%	100%	持平
正样本相似度	0.623	0.600	小幅下降
负样本相似度	0.266	0.270	稳定
平均边际 (Margin)	0.357	0.330	—

相较于原模型，微调模型的负样本区分度提升 48.8%，平均边际提升 66.4%。

4.6 分析

v1 的实验证明，在问答对数据上进行嵌入模型微调可以显著提升检索区分度。边际（Margin）从 0.238 提升至 0.396（+66.4%）意味着模型能更清晰地区分相关和不相关文档。正样本相似度的轻微下降（0.677→0.621）提示需要更多领域正样本以维持召回率。使用 `test_list_api.py`，检索效果没太大变化。考虑未来可以增多案例丰富数据再次试验。整体来看，v1 的微调是成功的，适合用于 RAG 系统的检索环节。

另外，RAG 对 LLM 缺乏的内容有明显的效果增强，问与知识库相近的问题，回答正确率 100%。但本次实验只准备了 4 个测试案例，后续需继续丰富审查逻辑。

5 v2 : Qwen3.5 LoRA 微调

5.1 实验目的

v2 的目标从向量模型的微调，转向后训练，使用 Qwen3.5-0.8B 多模态大语言模型，通过 LoRA 参数高效微调，实现针对模型未有的与 OpenClaw 相关的知识的答案生成。

5.2 数据与预处理

数据来源为 3.1 所提来自网络的 208 条关于 OpenClaw 的问答对(Query-Positive 配对)。按照 85/15 比例划分为训练集（175 条）和验证集（32 条）。数据格式化为“问题：{query}


回答：{pos}”的文本模板。

5.3 LoRA 训练配置

配置项	值
基础模型	Qwen3.5ForConditionalGeneration (0.75B 参数)
微调方法	LoRA (r=8, alpha=16, dropout=0.05)

目标模块	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj
可训练参数	$3,194,880 / 856,180,800 = 0.37\%$
训练轮数	30 epochs
Batch Size	8
学习率	$2e-4$
优化器	AdamW
学习率调度	线性预热（10%步数）后线性衰减

5.4 实验结果



训练耗时 10 分钟内，训练过程呈现出典型的过拟合模式：

指标	起始值	最终值	趋势
Train Loss	2.93	0.015	持续下降
Val Loss	1.11	0.764 (epoch 4 最优) $\rightarrow$ 1.65+	先降后升

最佳模型	—	epoch 4 (val loss = 0.764)	—
------	---	----------------------------	---

生成评估结果不理想：大量重复输出、欠拟合表现。

5.5 分析

v2 的关键问题是严重的过拟合。Train Loss 持续下降至接近 0，而 Val Loss 在 4 个 epoch 后开始回升，这是典型的过拟合信号。主要原因：（1）数据量过小（仅 175 条训练样本）；（2）epoch 数过多（30）；（3）验证集过小（32 条），评估不稳定。生成的答案出现重复循环或答非所问，表明模型并没有真正学会 QA 映射，而是机械记忆了训练数据。

6 v3 : Qwen3.5 继续预训练 CPT（中医领域注入）

6.1 实验目标

寻找中医针灸领域的数据，针对 Qwen3.5-0.8B-Base 模型，进行继续预训练，体验训练后模型效果。

6.2 数据与预处理


数据来源，来自 HuggingFace 的 6 个中医经典书籍文本 Markdown 文件，总计 452,466 字符，涵盖《黄帝内经·素问》、《黄帝内经·灵枢》、《针灸甲乙经》、《经络》、《腧穴》、《十二经脉_动画图》。

预处理流程：移除 Markdown 标记（#，*）→ 纯文本 → Token 化 → 分块。分块策略：max_length=512 tokens, stride=256（重叠），共生成 1,598 个块。训练/验证划分：1,438 / 160。

6.3 训练方法与核心特征

v3 采用继续预训练 (Continual Pre-training) 范式, 其核心特征是 $\text{labels} = \text{input}$ (纯文本续写任务)。这与 SFT 有本质区别: 模型学习的是预测下一个 token, 而非学习问答映射。训练使用全参数微调 (非 LoRA), Batch Size = 1, 梯度累积 8 步 (有效批次 = 8)。学习率 = $5e-5$, 训练 10 个 epoch。

6.4 实验结果



训练用时 4 小时 10 分钟, 是所有实验中最耗时的。

指标	初始值	最终值
Train Loss	2.84	≈ 0.009
Val Loss	2.52	≈ 1.75 (持续下降趋势)
Perplexity	≈ 12.4	≈ 5.75

Token Accuracy	57.6%	91.65%
----------------	-------	--------

6.5 对比测试结果与分析

使用问答方式对原模型和微调模型进行了对比测试，揭示了关键问题：

测试问题	原模型	CPT 微调模型
腹胀可以刺什么穴位？	思考后列出穴位	从《针灸甲乙经》开始续写经典原文
头痛可以刺什么穴位？	分析头痛类型，给出建议	从中医典籍中续写段落
十二经脉包括哪些？	正确列出经脉列表	从《黄帝内经-灵枢》续写文本
足三里的功效是？	给出详细功效说明	以经典格式列出功能和配伍

训练方法诊断：

（1）任务目标不同：CPT 的目标是文本续写（Next Token Prediction），而非问答。原模型是通用的问答模型，而 CPT 后模型学会了从经典中续写的模式。

（2）灾难性遗忘（Catastrophic Forgetting）：模型为了学会中医文本的语言模式（文言文风格、经典引用结构），大幅弱化了原有的通用问答能力。通用知识（语言理解、常识推理）和问答能力被破坏，而中医领域知识得到增强。

（3）评估方式错配：使用问答方式评估续写模型，本质上是评估维度的错误。CPT 的成功体现在 Loss 下降和 Token 准确率提升上，但这些指标与问答能力不直接对应。

7 v4 : Qwen3.5 LoRA

7.1 实验目标

使用 LLM 根据中医针灸经典书籍文本内容,自动生成问答对。再根据生成的问答对,通过 LoRA 微调 Qwen3.5-0.8B,观察这种方法生成的问答对,和对应微调后得到的模型的回答效果。

7.2 数据构建

项目 v4 的数据也是源自 HuggingFace 的 6 本中医针灸经典书籍文本内容,先分片,再用每个分片注入到 prompt 里,生成问答对。

分片逻辑如下:

每 3000 字符为一次理论分片长度,以理论分片长度读取临时分片。在该临时分片中寻找最后的句子结束符的位置,以此产生实际使用的分片。

生成问答对保存在 qa_dataset.jsonl,实例如下:

```
{"question": "五味阴阳之用如何区分?", "answer": "辛甘发散为阳, 酸苦涌泄为阴, 咸味涌泄为阴, 淡味渗泄为阳。", "source": "黄帝内经_素问.md", "chunk_id": 43}
```


7.3 训练配置

配置项	值
基础模型	Qwen3.5-0.8B-Base (AutoModelForCausalLM)
微调方法	LoRA (r=8, alpha=16, dropout=0.1)
目标模块	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj
训练轮数	10 epochs (实际完成约 3.6 epochs / 36 steps)
Batch Size	4, 梯度累积: 4
学习率	1e-4

精度	fp16
优化器	AdamW

7.4 实验结果

Qwen3.5-0.8B-Base LoRA Fine-tuning - Training Metrics



训练耗时 20 分钟。核心指标：

指标	初始值	最终值	变化
Train Loss	2.23	1.42	降幅 36.3%
Val Loss	1.94	1.45	降幅 25.3%
Perplexity	6.98	4.25	降幅 39.1%

Train/Val Loss 差距小 (1.42 vs 1.45)，无明显过拟合。

对比测试结果（原模型 vs LoRA 微调模型）：

测试问题	原模型	LoRA 微调模型
腹胀可以刺什么穴位？	足三里。（33 字）	足三里。（4 字，简洁）
头痛可以刺什么穴位？	手少阳三焦经。（7 字）	足太阳膀胱经。风池穴...（514 字，详细但重复）
十二经脉包括哪些？	手足阳明经...（34 字）	手足太阴、手足少阴、手足厥阴。（15 字）
针灸的禁忌有哪些？	针不能刺太深...（31 字）	1. 针不能入阴分；（10 字）
足三里的功效是？	主痹，四肢不仁。（8 字）	足三里，主升发胃气...（25 字，更专业）
膻穴的作用是什么？	膻穴是针灸治疗的直接作用部位。（15 字）	膻穴是治疗疾病的特定部位...（94 字，更详尽）

7.5 分析

v4 的 LoRA + SFT 方案在多项指标上取得了良好的效果：（1）Loss 显著下降且 Train/Val 差距小，表明模型学到有效知识且未过拟合；（2）Perplexity 降至 4.25，表示模型对中医文本的预测能力显著提升；（3）对比测试中，微调模型在部分问题上给出了更专业、更详尽的中医回答。

然而，部分回答仍存在重复问题（如头痛问题中“风池穴”重复约 100 次），说明在有限的训练步数（36 steps）下，模型尚未充分收敛。建议扩展问答对至 500+、训练 5-8 epochs、并加入重复惩罚机制。

8 总结

四个版本的数据量从 166 条到 1,438 条不等。值得注意的现象是：v2（175 条训练样本）出现了严重的过拟合，而 v4（161 条训练样本）却表现良好。这一差异的关键在于 v2 使用了 30 个 epoch，而 v4 仅使用了约 3.6 个 epoch。这说明在小数据场景下，早停（Early Stopping）和适当正则化至关重要。

另外，灾难性遗忘（Catastrophic Forgetting）是继续预训练中最核心的问题之一。v3 的实验为此提供了生动的案例：模型在学习中医文本续写的同时，严重退化了原有的通用问答能力。这种现象的根源在于神经网络的“稳定性-可塑性困境”（Stability-Plasticity Dilemma）：网络在学习新知识时必须调整权重，但这些调整可能覆盖原有的重要知识。而且预训练的耗时比较长，本次实验准备的数据量才 6 本书，却消耗了 4 小时去训练。中小企业用有限的资源做预训练，性价比不如等最新的开源模型使用。

对比 4 个版本，RAG 方案是最容易迁移，消耗资源最少的方案，而且在本实验小样本的情况下，这种方案的对问答任务的增强效果最优。

9 未来工作

数据扩展：将中医问答对扩展到 500-1000 条，覆盖更广泛的中医子领域（方剂、诊断、养生等）。

混合训练：实验 CPT + SFT 的两阶段训练流程，量化分析灾难性遗忘的实际程度。

多维度评估：除 Loss 和 Perplexity 外，引入 ROUGE、BLEU、BERTScore 等生成质量指标。

RAG 集成：将微调后的嵌入模型（v1 方案）与生成模型（v4 方案）结合，构建完整的 RAG 系统。

模型量化与部署：使用 GPTQ/AWQ 量化模型，实现在边缘设备上的高效推理。

参考文献

- [1] Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022.
- [2] Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP 2019.
- [3] BAAI. BGE-M3: Multi-Lingual, Multi-Granularity, Multi-Epoch Embedding Model.
<https://github.com/FlagOpen/FlagEmbedding>.
- [4] Qwen Team. (2025). Qwen3.5 Technical Report. Alibaba Group.
- [5] McCloskey, M., & Cohen, N. J. (1989). Catastrophic Interference in Connectionist Networks. The Psychology of Learning and Motivation.
- [6] Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. PNAS.
- [7] Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020.
- [8] 项目代码与实验数据: v1 - v4 目录, <https://github.com/EthanGD/NLPHomeWork20260530>.